

PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

IIC3103

Taller de Integración

Profesores

Arturo Tagle / Daniel Darritchon



Entrega 2

Desafíos e integraciones — 30% de la nota del proyecto

De la Entrega 1 a la Entrega 2

Entrega 1

Construir la distribuidora

- Abastecer y acondicionar kits
- Portal de venta propio
- Visor de trazabilidad de lote
- Modelo de custodia: qué unidad, de qué lote, dónde

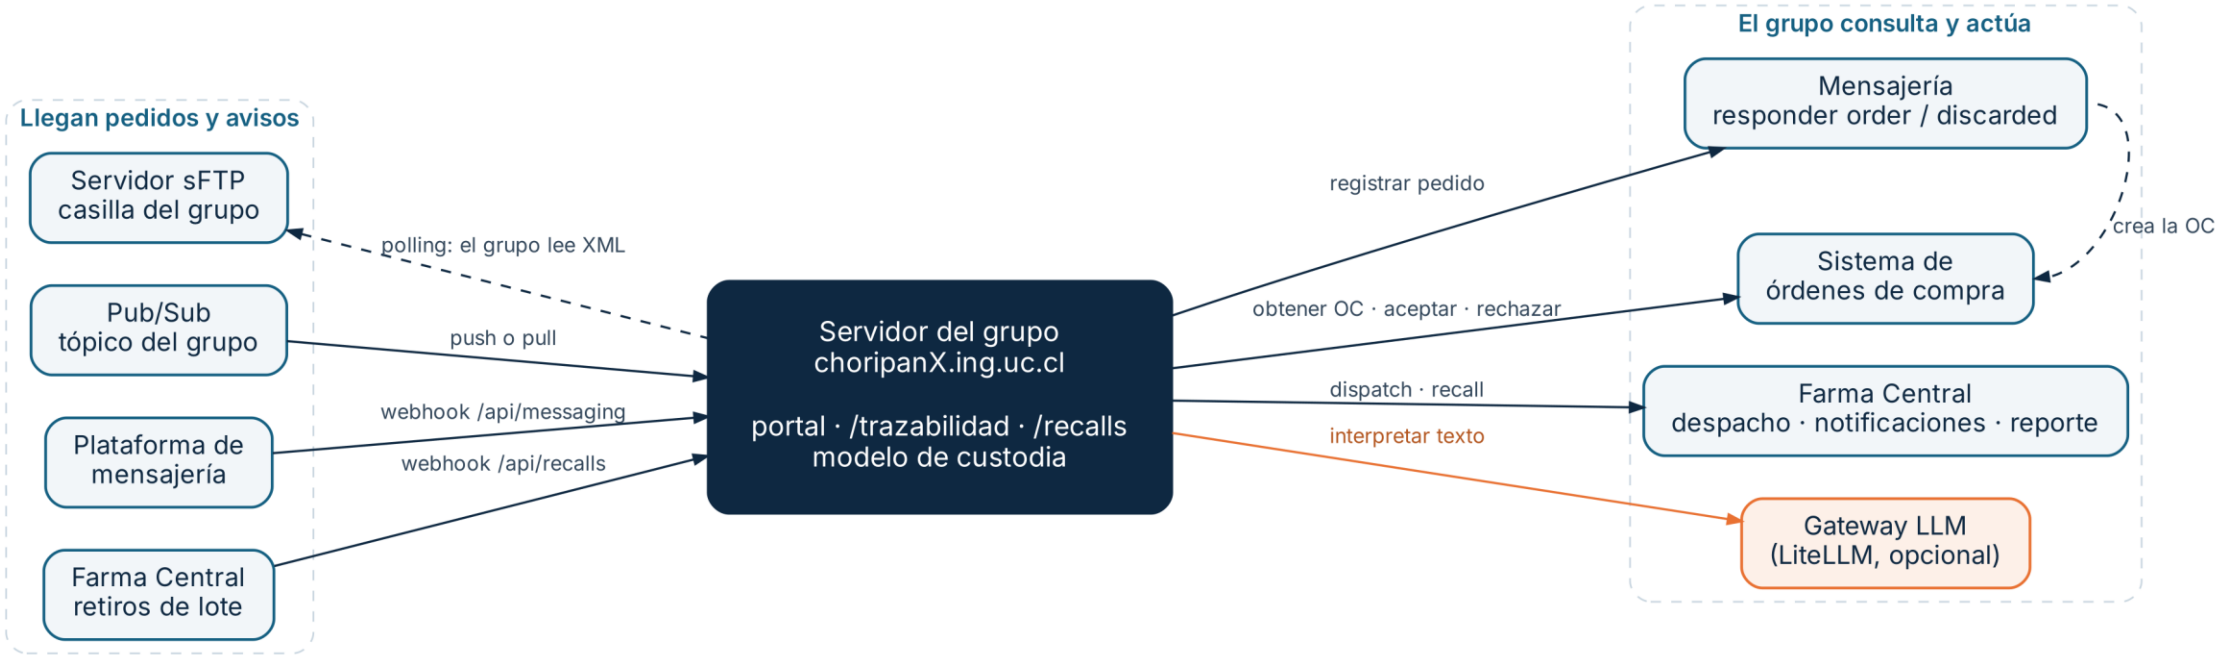
Entrega 2

Operarla sola, 36 horas

- Pedidos por tres canales: sFTP, Pub/Sub y mensajería
- Aceptar o rechazar y despachar dentro de plazo
- Interpretar lenguaje natural con un LLM
- Responder retiros de lote en 30 minutos

Las entregas son acumulativas. Lo que no funcione de la E1 —en especial el visor y el modelo de custodia— hay que completarlo ahora: es la base del retiro de lote.

Mapa de integraciones



Cuatro estilos de integración: polling de archivos (sFTP), cola de mensajes (Pub/Sub), webhooks entrantes (mensajería y retiros) y APIs REST salientes (órdenes, Farma Central, LLM).

Pedidos de clientes

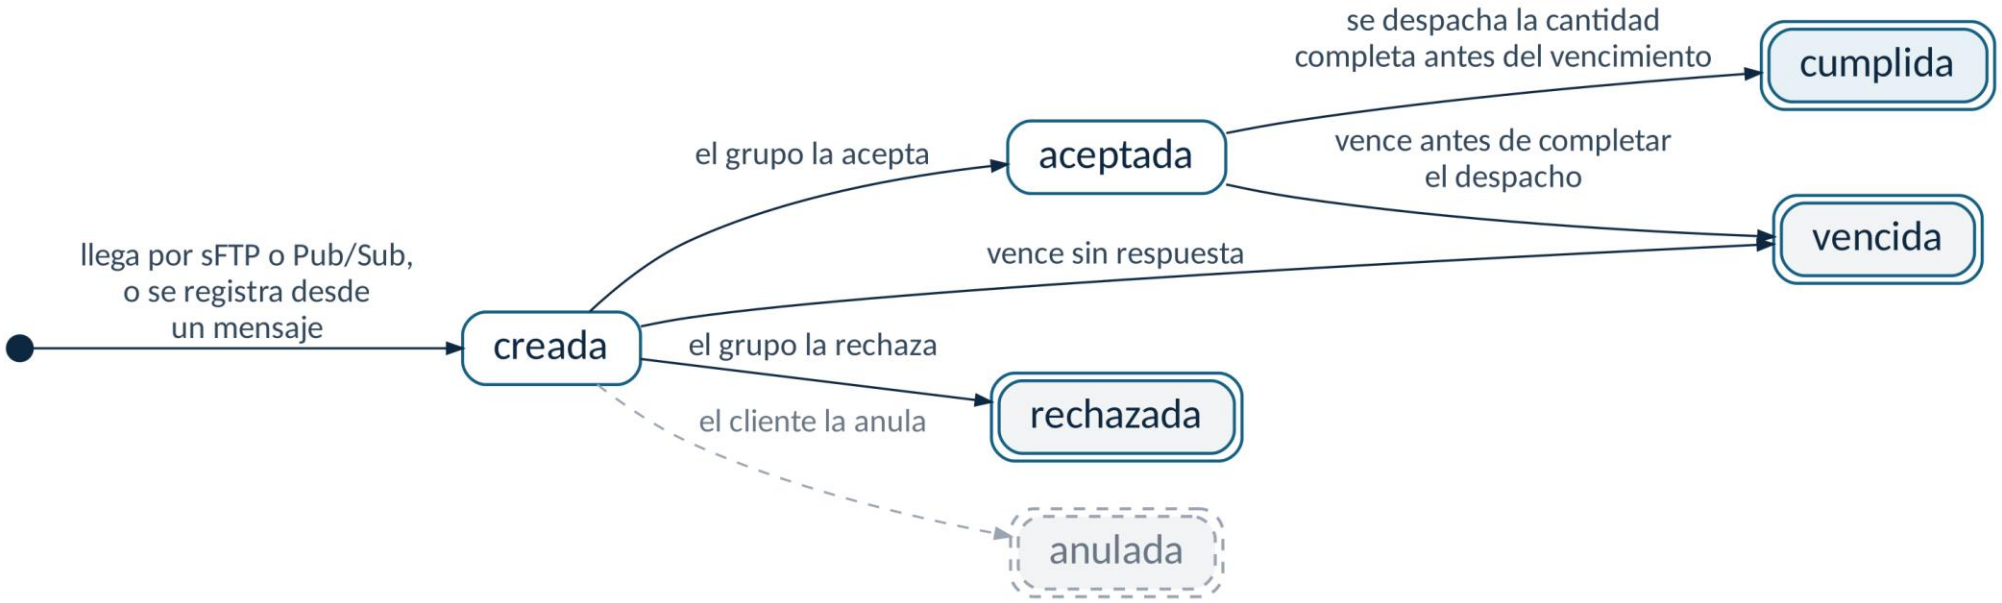
Tres canales, una misma fuente oficial: el sistema de órdenes de compra

Tres canales, tres patrones

Canal	Patrón	Qué trae	El desafío
sFTP	Polling de archivos	XML con el ID de la OC	Nadie avisa: revisar periódicamente, no repetir archivos y cerrar siempre las sesiones
Pub/Sub	Cola de mensajes (push o pull)	El ID de la OC, en base64	Entrega al menos una vez; suscripción propia y llave distinta por ambiente
Mensajería	Webhook entrante	Texto libre, sin OC asociada	Verificar OIDC, confirmar en < 15 s, interpretar con un LLM y crear la OC

El aviso no es el pedido. Antes de aceptar, consulten siempre la OC en el sistema de órdenes: sólo entrega una OC a la vez, por su ID.

Ciclo de vida de una orden de compra



Sin respuesta, no hay cumplimiento
Una OC que no se acepta nunca llega a cumplida, aunque se despache.

No dejar vencer las órdenes
Se puede despachar en partes; si vence antes de completar, no se considera cumplida.

Cada despacho, a la custodia
Qué unidad, de qué lote, a qué cliente y en qué OC.

sFTP y Pub/Sub: dónde se rompen

sFTP — casilla en choripan10.ing.uc.cl

- El servidor no avisa: hay que revisar la casilla periódicamente
- Los archivos ya leídos pueden seguir ahí: registrar qué archivos y qué OC se procesaron
- Sesiones simultáneas limitadas: cerrar la conexión siempre, también ante un error
- Al llegar al límite de conexión, los pedidos siguen llegando pero no se pueden leer

Pub/Sub — tópico propio por ambiente

- La suscripción la crea el grupo, con la llave de GET /ordenes-compra/pubsub/key
- Llaves distintas en dev y prod: cada una sólo opera su tópico
- Push: endpoint HTTPS propio y contenido en base64 en message.data
- Al menos una vez: un mensaje sin ack vuelve a llegar

Idempotencia en todos los canales

Un mismo aviso puede llegar dos veces. Nunca debe producir una aceptación ni un despacho doble.

Fuente del duplicado	Llave para reconocerlo
Archivo sFTP leído en dos revisiones	Nombre del archivo e ID de la OC
Mensaje de Pub/Sub reentregado (sin ack o ack tardío)	ID de la OC
Webhook de mensajería repetido, incluso tras responder 2xx	messageId
Webhook de retiro de lote repetido	recallId
Reintento propio tras un timeout: ¿se aplicó o no?	ID de la OC + estado local antes de actuar

Es uno de los cinco contenidos del informe de diseño: «Duplicados y reintentos».

Dimensionar la operación

~8

OC/hora

entre sFTP y Pub/Sub

~3

mensajes/hora

por mensajería, en su mayoría pedidos

1–2

kits por pedido

~2 h

de plazo

OC de sFTP y Pub/Sub

36 h

de operación

mar 27 10:00 → mié 28 22:00

≈ 290 OC y ≈ 100 mensajes
en el período, según los valores esperados. Los reales pueden variar.

¿Alcanzan 2 horas?
Abastecer y acondicionar desde cero después de recibir el pedido puede no caber en el plazo: la estrategia de stock de la E1 se pone a prueba aquí.

Meta 80%
Se mide cumplidas sobre recibidas. Con 80% o más, puntaje completo: rechazar o dejar vencer cuentan igual como no cumplidas.

Canal de mensajería

Pedidos en lenguaje natural: un componente no determinista dentro de un flujo que compromete a la distribuidora

Del webhook a la orden de compra

Síncrono: < 15 s	Asíncrono: ≤ 30 min desde receivedAt	Flujo de OC

1 Recibir

POST /api/messaging con token OIDC

2 Confirmar

Verificar token, deduplicar por messageId y responder 2xx

3 Interpretar

LLM fuera del request: SKU, cantidad y fecha

4 Validar

Contra el catálogo y las reglas del negocio

5 Responder

order o discarded, una sola vez

6 Decidir

Aceptar o rechazar la OC creada y despachar

Dos decisiones separadas: qué pidió el cliente se declara al responder el mensaje (paso 5); si la distribuidora lo toma se decide al aceptar o rechazar la OC (paso 6).

El webhook: cuatro reglas

1

Autenticación

Token OIDC de Google: verificar firma, emisor, audiencia (la URL exacta del servicio) y vigencia. Lo que no cumpla, 401.

2

Confirmación

2xx en menos de 15 s. Si no, la plataforma reintenta con esperas crecientes por un tiempo acotado; agotados, el mensaje se pierde.

3

Duplicados

Entrega al menos una vez: un mensaje puede repetirse incluso después de un 2xx. La llave es messageId.

4

Tiempo de respuesta

Interpretar con un LLM puede tardar más de 15 s. Confirmar de inmediato y procesar después.

Las mismas reglas aplican al webhook de retiros **/api/recalls**. Ejemplo de verificación en el Anexo 3 del enunciado.

Interpretar: del texto al pedido

Farmacia Los Aromos · receivedAt 2026-10-27T16:05:00Z

«Hola, buenas tardes. Les escribe Rosa de la Farmacia Los Aromos. Necesito dos kits respiratorios para adulto, los que traen amoxicilina, para hoy antes de las 7 de la tarde. Gracias!»



Interpretación correcta

```
{
  "sku": "KIT-RESP-ADULTO",
  "quantity": 2,
  "deliveryDate": "2026-10-27T22:00:00Z"
}
```

Kit (SKU)

Por su uso, sus componentes, un principio activo o palabras del cliente: «el de la diabetes».

Cantidad

En palabras: «dos», «un par», «media docena».

Fecha y hora

Relativa a receivedAt y en hora de Chile: «hoy antes de las 7», «en tres horas», «mañana a primera hora».

Descartar también es responder bien

«Comprometerse con un pedido mal interpretado es peor que descartarlo.»

Ante la duda, descartar con un reason claro.

× **No es un pedido**
Preguntas por pedidos anteriores, pedidos de ayuda, otras solicitudes

× **Ambiguo**
Podría ser cualquiera de dos kits

× **Fuera del catálogo**
Pide algo que no es un kit clínico

× **Sin cantidad**
No se especifica cuántos

× **Plazo vencido**
Pide una fecha que ya pasó

Una sola respuesta por mensaje, dentro de 30 minutos. Un mensaje sin respuesta cuenta como error.

Nadie les dirá si interpretaron bien

Interpretación — 10 pts

¿Qué pidió el cliente?

- Pedidos registrados con SKU, cantidad y fecha correctos (fecha ± 15 min)
- Descartados los que no se podían cumplir y los que no eran pedidos
- Rechazar la OC de un pedido bien registrado no afecta este ítem

Cumplimiento — 10 pts

¿Se entregó lo que pidió?

- El kit que pidió, al menos en la cantidad que pidió, antes del plazo que pidió
- Se mide contra lo que el cliente pidió, no contra lo declarado
- Otro kit, menos unidades o fuera de plazo: no cuenta como cumplido

La OC avanza con lo que el grupo declaró y vence en la deliveryDate declarada. Una interpretación equivocada puede costar en los dos ítems a la vez.

El LLM como componente del sistema

Gateway del curso

LiteLLM, con API compatible con OpenAI

- Una clave por grupo y por ambiente
- Presupuesto diario de uso
- Varios modelos, cada uno con su costo por token
- Uso opcional: se puede usar otro proveedor, a costo del grupo

1

Elegir el modelo

Varios modelos, con distinto costo por token y capacidades: decidir cuál usar es parte del desafío.

2

Validar la salida

Un SKU en la respuesta no garantiza que exista: validar contra catálogo y reglas antes de registrar.

3

Plan B

¿Qué pasa si el modelo duda, falla o se agota el presupuesto? El plazo de 30 min sigue corriendo.

4

Registrar cada decisión

Qué texto se interpretó, qué respondió el modelo y qué decidió el sistema, para poder revisarlo después.

Retiro de lote

30 minutos para demostrar que el modelo de custodia funciona

Los 30 minutos de un retiro

issuedAt · t = 0

deadline · t = 30 min

Aviso: POST /api/recalls (o GET /farma-central/recalls)

Vale lo recibido hasta aquí

1 Aislar

Mover a cuarentena todas las unidades en stock del lote y de los lotes generados a partir de él, recursivamente. Sacarlas del portal de venta.

Movimientos en Farma Central

2 Notificar

Por cada OC en que se despacharon unidades afectadas: la OC, el cliente y las unidades.

POST .../recalls/{recallId}/notifications

3 Reportar

Stock afectado y su espacio, lotes derivados y entregas a clientes: las preguntas 1, 2 y 3 de trazabilidad.

POST .../recalls/{recallId}/report

El plazo corre desde issuedAt, haya llegado o no el aviso. El reporte se puede reenviar: vale el último recibido dentro del plazo.

Por qué el retiro es difícil

Es recursivo
Del lote retirado salen productos acondicionados, y de esos, kits. Todo lo derivado también se retira.

La cuarentena no se deshace
Es de sólo entrada: lo que entra no se mueve, no se consume y no se vende.

Reportar de más resta
Una unidad ajena al lote o sus derivados, reportada, notificada o en cuarentena, cuenta como error.

No hay feedback en línea
Farma Central confirma que recibió el reporte, no si es correcto.

Llega sin aviso previo
Varios retiros durante el período. Cuenta el mejor respondido: basta con uno correcto.

Se puede practicar
En dev, gatillar retiros desde el portal de grupo. Al vencer, el portal muestra la respuesta correcta.

Además: listado de retiros en **/recalls**, con el SKU y el ID de cada producto retirado. Puede ser parte del visor de trazabilidad.

Operación y evaluación

Todo se evalúa en producción, durante el período de evaluación

36 horas de operación continua

5 min entre consultas a / y /trazabilidad

< 10 s para contar como disponible

90% meta de consultas exitosas

Se recomienda no tener nada manual

Polling, colas, reintentos, aceptación y despacho corren solos, de día y de noche.

El portal no puede esperar

Proof-of-work, LLM y polling no deben bloquear el portal ni el visor.

Caídas y reinicios

¿Qué pasa con un mensaje o una OC a medio procesar si el proceso se reinicia?

Enterarse antes

Logs y alertas propias: no esperar a que el pinger descubra la caída.

Rúbrica preliminar (100 puntos)

Ítem	Cómo se mide	Pts
OC por sFTP	% cumplidas sobre recibidas	17,5
OC por Pub/Sub	% cumplidas sobre recibidas	17,5
Mensajería: cumplimiento	% de pedidos cumplibles cumplidos	10
Mensajería: interpretación	% de mensajes bien resueltos	10
Retiro: reporte	Cobertura, descontando lo reportado de más	8
Retiro: portal	Listado y detalle en /recalls	2
Retiro: notificaciones	OC bien notificadas, menos las de más	5
Retiro: cuarentena	Unidades en cuarentena al vencer el plazo	5
Retiro: tiempo	Reporte dentro de 30 minutos	3
Operación continua	% de consultas exitosas, meta 90%	10
Informe de diseño	Cinco contenidos en partes iguales	12

35 Órdenes de compra

23 Retiro de lote

20 Mensajería

12 Informe

10 Operación continua

Descuentos:
−5 sin declaración de IA en el informe
−5 si el repositorio no está actualizado

Informe de diseño

1. **Canal de mensajería**
   Diagrama de secuencia instanciado en el mensaje de ejemplo, hasta que la OC queda aceptada o rechazada

2. **Retiro de lote**
   Diagrama de secuencia hasta el reporte: qué consultas de custodia y por qué terminan en < 30 min

3. **Salida no determinista**
   Cómo se valida al modelo y qué pasa cuando duda, falla o se agota el presupuesto

4. **Duplicados y reintentos**
   Cómo un mensaje repetido, por cualquier canal, no genera aceptación ni despacho doble

5. **Cambios al modelo de custodia**
   Qué cambió respecto de la E1 y por qué

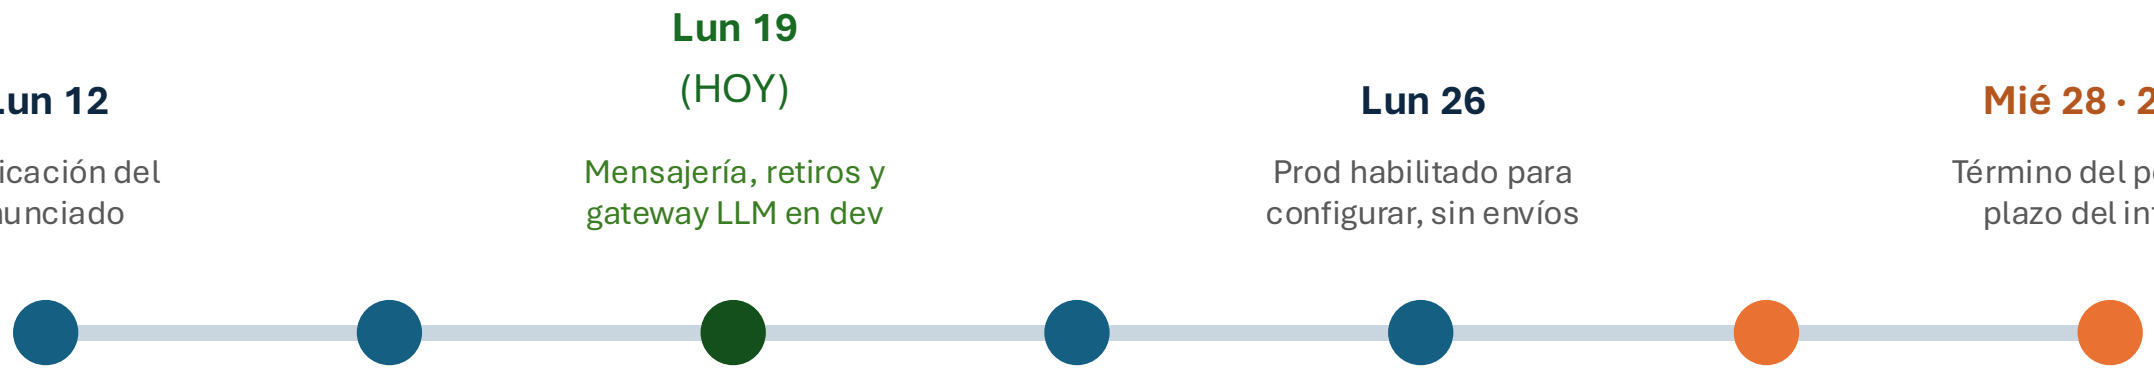
≤ 6 páginas

sin contar diagramas, en PDF en Canvas antes de mié 28 a las 22:00

Declaración de IA
incluidos los modelos que son parte del sistema, como el que interpreta los pedidos

Defensa oral
dirigida o aleatoria, sobre cualquier parte del código o del diseño

Calendario de disponibilidad



Lunes 26: Probar en producción

Credenciales, suscripción de Pub/Sub, webhooks, conexión con el Gateway, etc

Detalles que conviene no pasar por alto

Órdenes de compra

- Una OC sin aceptar nunca queda cumplida, aunque se despache
- El XML de sFTP no es la fuente oficial: consultar la OC
- Una sesión sFTP que quedó abierta tras un error sigue ocupando una sesión en el servidor
- Las llaves de Pub/Sub de dev no sirven en prod

Webhooks y mensajería

- Responder 2xx no evita que el mensaje vuelva a llegar
- La audiencia del token OIDC es la URL exacta del servicio
- «Hoy» se calcula desde receivedAt, en hora de Chile
- La OC de mensajería vence en la deliveryDate declarada, no en la que pidió el cliente

Retiro y entrega

- Lo que está en cuarentena no puede aparecer disponible en el portal
- Repositorio actualizado al inicio del período (−5)

Cambiar o no cambiar en producción

Si algo no funciona, corríjanlo

Es un sistema en producción: mientras algo falla se pierden pedidos, mensajes o disponibilidad. Es mejor hacer un cambio que dejarlo sin funcionar.

VS

Pero cada cambio es un riesgo

Tocar un sistema que está operando puede introducir inestabilidad y nuevos errores en partes que hasta ahora funcionaban.

Siempre habrá un trade-off entre no hacer cambios y hacerlos. Decidan caso a caso.

Para que un cambio en producción sea menos riesgoso:

- **Pequeño y acotado**
- **Probado antes en dev**
- **Con forma de volver atrás**
- **Observación tras desplegar**

Declaración de uso de IA

1 Herramienta

Claude, de Anthropic.

2 Tareas asignadas

Revisión del enunciado de la Entrega 2, propuesta de estructura, redacción de láminas y elaboración de los diagramas.

3 Verificación

El contenido se contrastó con el enunciado de la Entrega 2. El equipo docente revisó, editó y ajustó las láminas.

El contenido de esta presentación es responsabilidad del equipo docente, con independencia de las herramientas usadas para prepararla.



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

IIC3103

Taller de Integración

Profesores

Arturo Tagle / Daniel Darritchon